

GOOGLE SKILLS SCRAPER

Trích Xuất Nội Dung Của Google Skills Vào Kho Kiến Thức Cá Nhân (PKB)

Đinh Xuân Sâm | 25410291

Tháng 09/2026

NỘI DUNG

1 BỐI CẢNH

- Một Bộ Não Thu Nhỏ – A Vault
- skills.google – Tiểu Sử
- Phân Cấp Dữ Liệu
- ...

2

2 MỘT TIỆN ÍCH NHỎ

- Lịch Sử Công Cụ
- Triết Lý Unix Trong Code
- Vì Sao Chỉ Terminal
- ...

9

3 TRỌNG TÂM `/model/`

- Package Và Module
- Sơ Đồ Lớp Của `model/`
- Class Và Object
- ...

14

4 DEMO

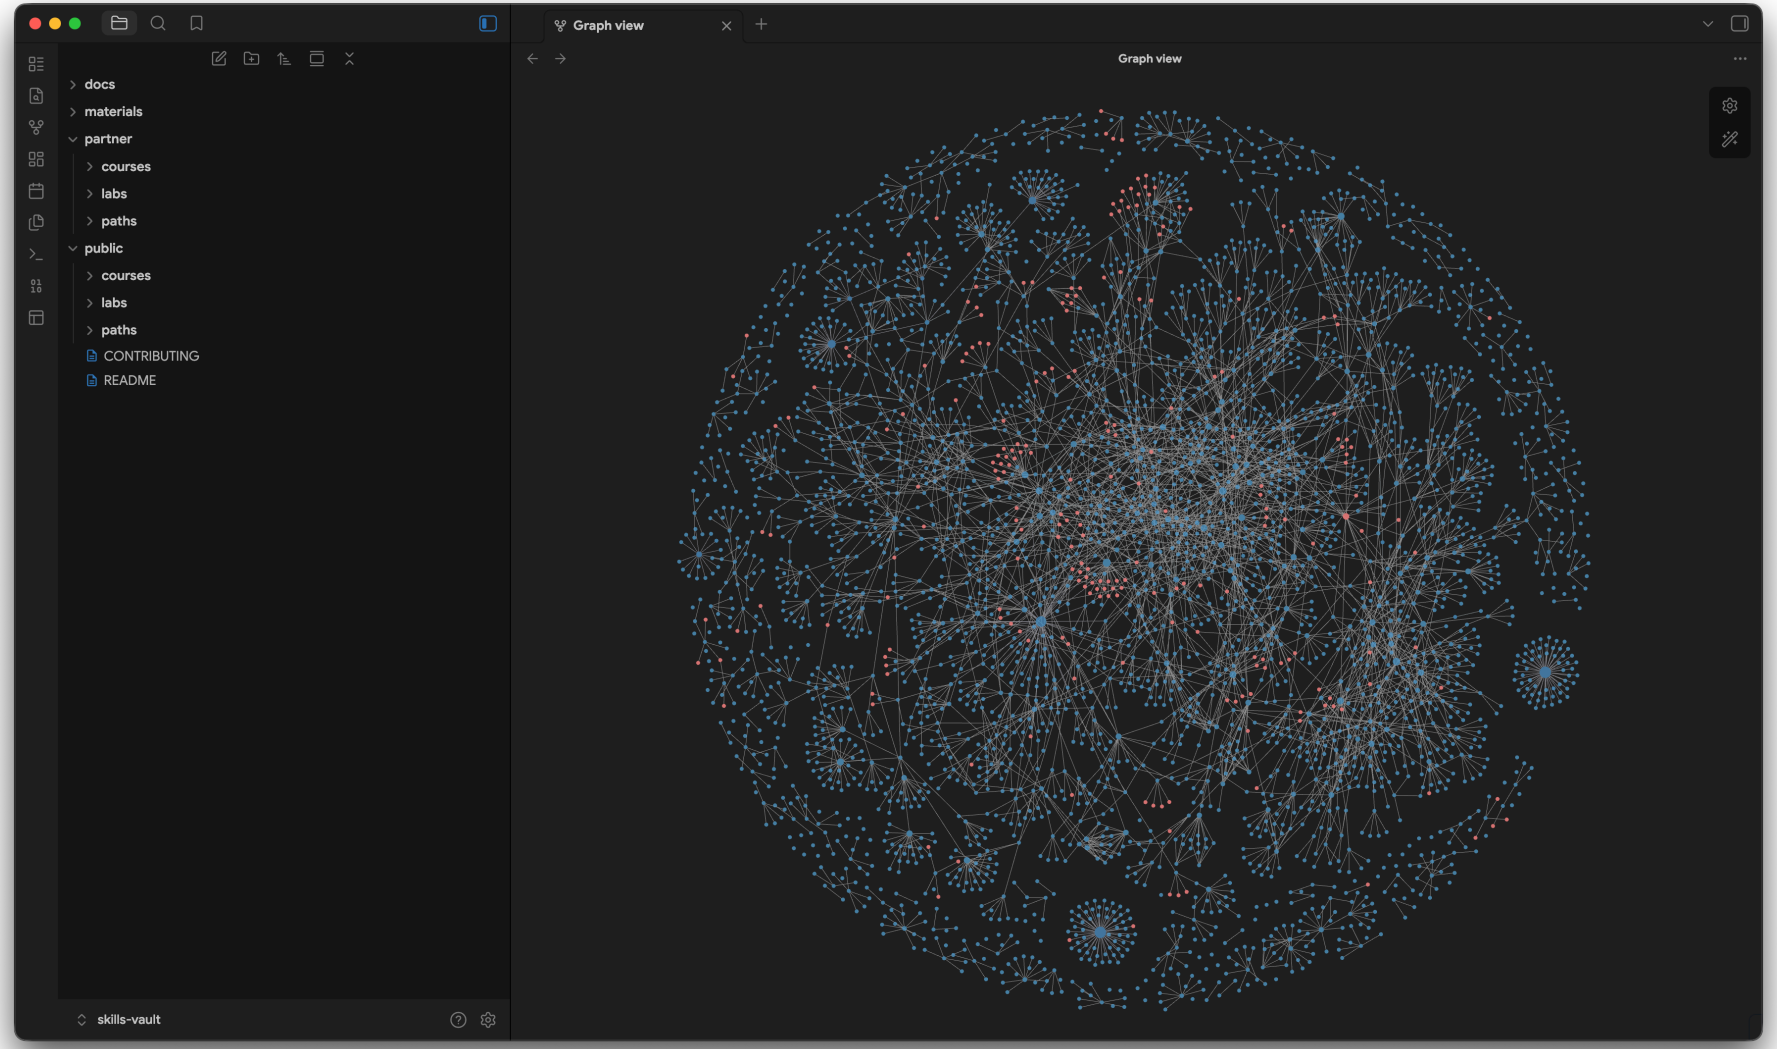
- TUI
- CLI
- Cảm Ơn

25

01

BỐI CẢNH

1.1 MỘT BỘ NÃO THU NHỎ – A VAULT



Mỗi chấm là một **path**, **course** hoặc **lab** trên skills.google.

Giới Thiệu

- Một portal e-learning: *"Bởi Google và cho Google."*

1 Cloud Skills Boost

- *cloudskillsboost.google*
- Tập trung Google Cloud.
- Không cần tài khoản.
- `ql-course-outline`.

2 Google Skills

- *skills.google*
- Phục vụ nhiều sản phẩm của Google.
- Phải có tài khoản đăng nhập.
- `ql-contents-menu`.

Hệ quả kỹ thuật

- Công cụ phải có **phiên đăng nhập**, mọi *request* đi qua nó, (*scraper*, không phải *crawler*).

1.3 PHÂN CẤP DỮ LIỆU

```
Portal (public | partner)
└─ Path (learning path)
  └─ Course
    └─ Module
      └─ Step
        └─ Activity
          └─ video | lab          | quiz          |
          └─ link  | document     | html_bundle   |
          └─ badge | credential   | ...
```

M Mô Hình Hóa

- Thực thể: **Path**, **Course**, **Lab**.
- Dữ liệu: `modules`, thuộc Course.
- Module: `src/skills_scaper/model/`.

! Ghi Chú

- **Lab**: `lab`
  - vừa là **Activity** trong **Course**
  - vừa là **thực thể** độc lập.
- **Activity** thuộc về Google: thêm/bớt.

1 Course này thuộc Path nào?

- Site:
  - dò tìm ngược thủ công.
  - có khi không tìm được.
- Vault: **backlink** của note, tức thì.

2 Hai Path trùng nhau bao nhiêu?

- Site: không có / không rõ.
- Vault:
  - nút chung trên **graph**, hoặc
  - một truy vấn Dataview.

3 Ở đâu nói "Vertex AI Pipelines"?

- Site: không tìm trong transcript.
- Vault: offline
  - `grep` hoặc
  - ô tìm kiếm.

4 Google đổi gì từ lần học trước?

- Site: không có changelog.
- Vault:
  - `date_published` (property);
  - `git diff`.

Có thể bạn đã biết. Color Palette của Google.

1.5 OBSIDIAN VAULT LÀ BỘ NÃO THỨ HAI

C Capture

- scraper
- tự động
- lặp lại được.

O Organize

- `paths/`
- `courses/`
- `labs/`

D Distill

- `--toc`,
- `--no-transcript`,
- `<id>-prompt.json`.

E Express

- ghi chú riêng
- scraper **không đụng tới**.

```
skills-vault/
├── public/
│   ├── paths/      # 73
│   ├── courses/    # 416
│   └── labs/       # 824
├── partner/
│   ├── paths/      # 181
│   ├── courses/    # 899
│   └── labs/       # 1209
├── materials/courses/<id>/  # thư mục PDF
├── docs/  README.md  CONTRIBUTING.md
```

R Trách Nhiệm

- Scraper:
  - **C** và một phần **D**.
- Người dùng:
  - **O** và **E**.
- KISS: *Keep It Simple, Stupid.*

https://fortelabs.com/blog/basboverview/

OKF v0.2

- mọi `.md` có frontmatter YAML với `type` không rỗng.

OKF v0.2	Vault (v2.0.0)	Trạng thái
`type` (bắt buộc)	`type: Course`	Khớp, `self.__class__.__name__`
`title`	`title`	Khớp, đổi từ `name`
`resource`	`url`	Cùng nghĩa, khác tên
`tags`	`topics`	Cùng nghĩa, khác tên
`description` ở frontmatter	`description` trong thân	Đã chuyển lên frontmatter
`sources`, `generated`	không có	Thêm: `last_modified`, `skills-scraper/<version>`
`index.md`, `log.md`	`paths.md`	Thiếu, cần bổ sung

GoogleCloudPlatform/open-knowledge-format, Aug 2026.

02

MỘT TIỆN ÍCH NHỎ

1 **12/2024 – 01/2025**

- Self-enablement.
- Những commit đầu tiên.
- Cloud Skills Boost.

2 **02/2026, v2.0.0**

- Giờ là skills.google.
- CLI, interactive
- TinyDB + JSON.

3 **09/2026, v2.0.1**

- Fork từ v2.0.0.
- Cập nhật, đóng gói.
- Môn IE221.

Repo

- Lưu tại `github.com/ggcta/skills-scrapper`.
- Cùng một tác giả ở một vai trò khác.

ggcta = Google Cloud Technical Architect

2.2 TRIẾT LÝ UNIX TRONG CODE

1 PLAIN TEXT!

JSON và Markdown thuần. `git diff` được, `jq` được, `grep` được.

2 KISS

- `fetch`: lấy về JSON. `md`: JSON ra Markdown.
- Không (cần) biết nhau.

3 Pipelining

```
skills-scraper list -c | grep -i Vertex;
```

4 Stateless

- Đọc file, ghi file, thoát.
- Không daemon, không DB.
- Chạy lại là idempotent nhờ `datePublished`.

5 .conf

`config.yaml` và biến môi trường `CSB_*`. Không có đường dẫn cá nhân trong code.

6 real-world

- ZSphere TUI, VxRail platform-service trên ESXi.
- Thành phần nhỏ, module, stateless của hệ thống lớn.

2.3 VÌ SAO CHỈ TERMINAL

C CLI: `skills-scraper`

- `argparse`, subcommand, mã thoát.
- Cho **scripting và automation**: gọi từ shell, cron, công cụ khác.
- `list`, `fetch`, `md`, `search`, `reindex`, `browser`.

T TUI: `*-tui`

- Vòng lặp menu, màu ANSI, kiểu classic interactive.
- Cho **tương tác**: chọn path, chọn course, làm luôn.
- Siêu gọn, đa nền tảng, không phụ thuộc thêm.

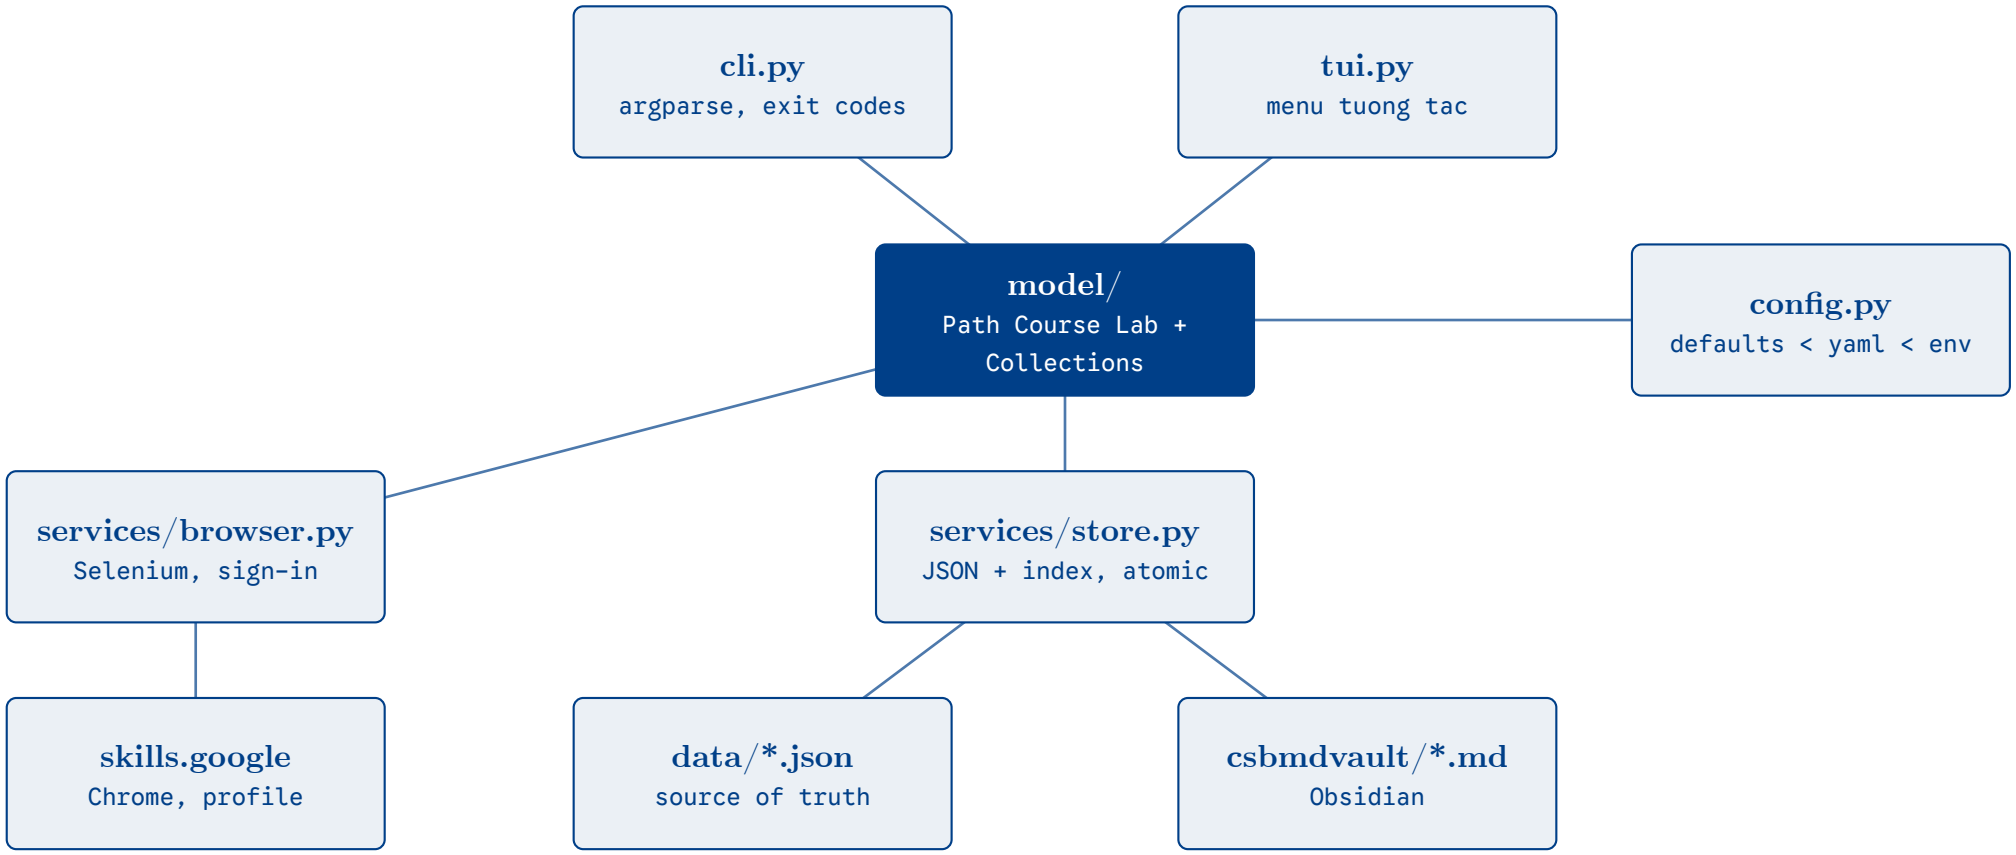
G !GUI, !web

- User: kỹ sư hệ thống trong terminal.
- GUI là một lựa chọn.
- Mở rộng: Desktop GUI Tauri.

Hai runner, **một lõi**:

- cả hai chỉ khởi tạo lớp trong `model/` và gọi phương thức.
- Đổi giao diện không sửa `model/`.

2.4 KIẾN TRÚC



Phụ thuộc một chiều: runner gọi model, model gọi services, services lầm việc với file và trình duyệt (các tài nguyên).

03

TRỌNG TÂM /model/

3.1 PACKAGE VÀ MODULE

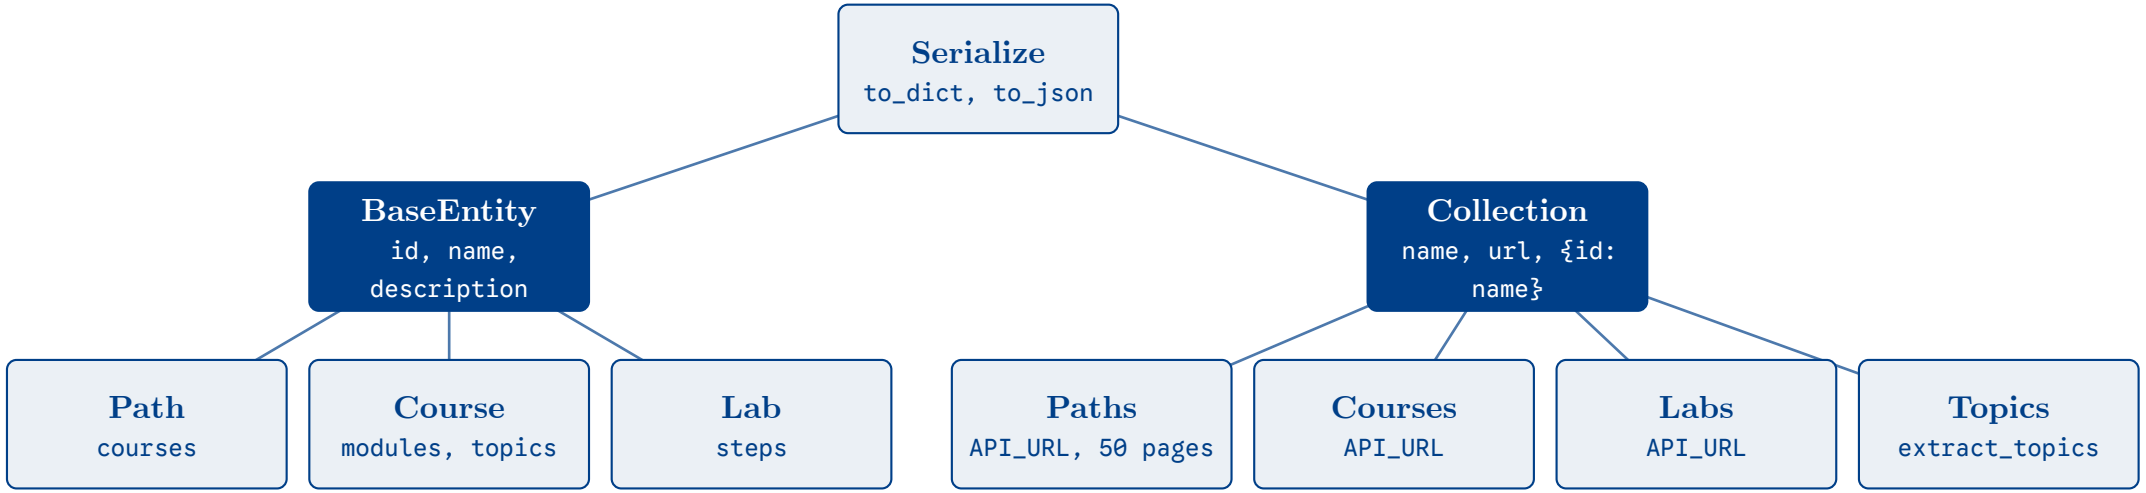
```
src/skills_scraper/
├── __init__.py      # __version__
├── config.py        # defaults < yaml < env
├── cli.py           # cli (Command Line Interface)
├── tui.py           # tui (Text User Interface)
├── model/           # LÕI QUAN TRỌNG
│   ├── __init__.py  # __init__
│   ├── base_entity.py
│   ├── collection.py
│   ├── path.py
│   ├── course.py
│   ├── courses.py
│   ├── lab.py
│   ├── labs.py
│   ├── paths.py
│   └── serialize.py
├── services/
│   ├── __init__.py  # __init__
│   ├── browser.py   # browser (Selenium)
│   └── store.py     # store (JSON, index, atomic)
└── utils/
    ├── __init__.py  # __init__
    └── utils.py
```

```toml
[project]
name = "skills-scraper"
version = "2.0.1"
```

```toml
[project.scripts]
skills-scraper = "skills_scraper.cli:main"
skills-scraper-tui = "skills_scraper.tui:main"

[build-system]
requires = ["uv_build>=0.8,<0.13"]
build-backend = "uv_build"
```

3.2 SƠ ĐỒ LỚP CỦA MODEL/



1 Trái: thực thể x

`BaseEntity` biết id, tên, mô tả, đường dẫn file và cách ghi JSON, Markdown. Lớp con chỉ thêm dữ liệu riêng và cách render.

2 Phải: danh sách x

`Collection` là `{id: name}` cộng `fetch_catalog`. Lớp con chỉ khai `API_URL`.

3 Composition

- `Course` tạo `Lab` và cập nhật `Labs`;
- `Path` giữ dict course;
- `Topics` đọc `Courses`.

model/base_entity.py

```python
    def __init__(self,
                 id: str,
                 name: str,
                 description: str):
        self.id = id
        self.name = name
        self.description = description
```

```python
    @property
    def type(self):
        """
        Dynamically determine the type based on the class name.
        """

        return self.__class__.__name__
```

```python
    @property
    def url(self):
```

```python
        base_url = {
            "Path": BASE_URL_PATHS,
            "Course": BASE_URL_COURSES,
            "Lab": BASE_URL_LAB
        }.get(self.type, None)

        if not base_url:
            raise ValueError(f"Invalid entity type: {self.type}")

        return f"{base_url}/{self.id}"
```

P `@property`, không lưu mà suy ra

`type` là `self.__class__.__name__`: lớp con **luôn có**. frontmatter có `type` "miễn phí" và thoả OKF ngay từ đầu.

O Object có trạng thái và tài nguyên

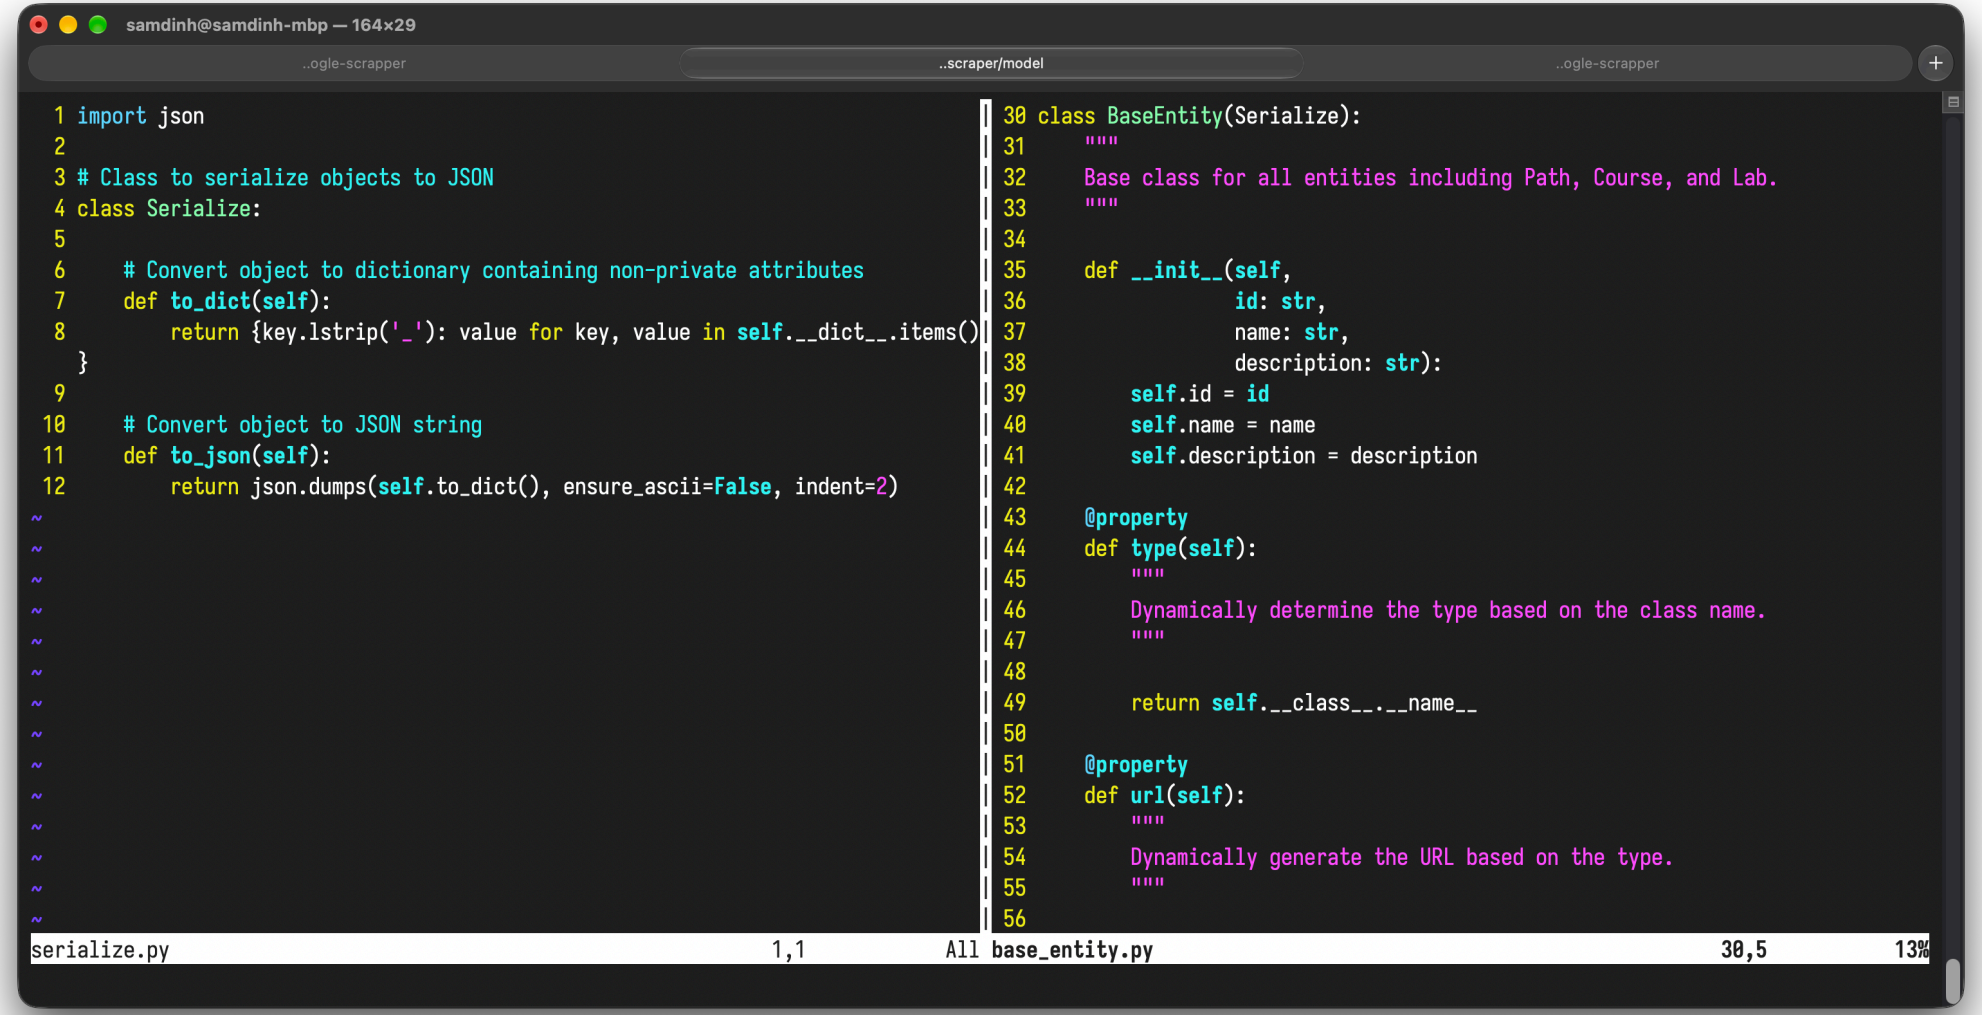
`Course(id="892", driver=driver)`:

- `modules`, `topics` là trạng thái; được serialize.
- `driver` là tài nguyên, **không** được serialize.

! Xử lý ngoại lệ

`url` throws `ValueError` cho `type` lạ (nếu có) thay vì trả về `None`.

3.4 KẾ THỪA – VÍ DỤ



`model/base_entity.py`: lớp cha

```python
    def generate_markdown(self, **kwargs) -> str:
        """
        Generate the Markdown representation of the entity.
        """

        # Convert the Path object to a dictionary
        markdown = []
        markdown.append(self.generate_front_matter())

        return "\n\n".join(markdown) + "\n"
```

```python
    def save_markdown(self, **kwargs) -> None:
        """
        Save the Path data to a Markdown file.
        passes kwargs to generate_markdown
        """

        write_text(self._md_path, self.generate_markdown(**kwargs))
```

`model/lab.py`: lớp con ghi đè

```python
class Lab(BaseEntity):
    """
    Class representing a Lab entity.
    """

    def __init__(self,
                 id: str,
                 name: str = None,
                 description: str = None,
                 steps: dict = None):
        super().__init__(id,
                         name,
                         description
                         )
        self.steps = steps or {}
```

```python
    def generate_markdown(self, toc_only: bool = False, **kwargs):
```

Template method

- `save_markdown` ở lớp cha gọi `self.generate_markdown(**kwargs)` mà không (cần) biết lớp con nào đang chạy.
- `Path`, `Course`, `Lab` mỗi lớp một bản.
- Một lệnh `md -c / -p / -l` trong CLI chạy ba nhánh chỉ khác **lớp được khởi tạo**.

3.6 KẾ THỪA THAY CHO BA BẢN COPY

`model/collection.py`: một vòng phân trang cho cả ba

```
    def fetch_catalog(self, force: bool = False) -> bool:
```

```
            while True:
                print(f"Fetching page {page}...", end='\r')
                page_html = get_page(self.driver, f"{self.API_URL}&page={page}",
f"{label} page {page}")
                if page_html is None:
                    break

                # The browser renders the JSON response inside <pre>.
                pre_element = page_html.select_one("pre")
                json_text = pre_element.get_text() if pre_element else
page_html.get_text()
```

```
                page += 1
                if page > self.MAX_PAGES:
                    print(f"\nReached safety limit of {self.MAX_PAGES} pages.")
                    break
```

`model/paths.py`: lớp con chỉ còn dữ liệu

```
class Paths(Collection):
    """
    Class representing a collection of paths.
    """

    API_URL = API_URL_PATHS
    MAX_PAGES = 50

    def __init__(self,
                 name: str = None,
                 url: str = BASE_URL_PATHS,
                 collection: dict = None,
                 driver=None):
        super().__init__(name, url, collection, driver)
```

Một `fetch_catalog` ở `Collection`, lớp con khai **thuộc tính lớp** `API_URL` và `MAX_PAGES`, còn `fetch_paths` giữ tên để CLI tra bằng `getattr(collection, f"fetch_{label}")`.

3.7 ĐÓNG GÓI VÀ COMPOSITION

`BaseEntity.to_dict`: lưu gì ra đĩa

```
        the_dict = {k: v for k, v in self.__dict__.items() if not
k.startswith('_') and k != 'driver'}
        the_dict['type'] = self.type
        the_dict['url'] = self.url

        # Add scrapedTime (epoch in milliseconds)
        the_dict['scrapedTime'] = int(time.time() * 1000)

        return the_dict
```

`Course.process_lab`: một course tạo ra một lab

```
            lab = Lab(
                id=lab_id
            )
            # Load the lab data from JSON even it's empty
            lab.load_json()

            # If the lab.name does exist, that means the lab has been
extracted already.
            if lab.name:
                print(f"(process_lab) •-• [+] Existed: {lab.id} -
{lab.name}")
                return False
```

_ Đóng gói theo quy ước

- `_json_path`, `_md_path` là chi tiết nội bộ.
- `to_dict` lọc mọi khoá (có tiền tố) _ và khoá `driver`:
  - JSON trên ổ đĩa không bao giờ chứa tài nguyên hay đường dẫn nội bộ.

+ Composition, idempotent

- `Course` tạo `Lab(id)`, `load_json()`; đã có tên thì bỏ qua, chưa có thì `save_json()`, `save_markdown()` rồi cập nhật `Labs`.
- Chạy lại không tạo trùng.

Rẽ nhánh bằng dict, loại lạ thì giữ

```
        handlers = {
            "video": self.process_video,
            "lab": self.process_lab,
            "quiz": self.process_quiz,
            "link": self.process_link,
            "html_bundle": self.process_link,
            "document": self.process_document,
        }
```

```
            handler = handlers.get(activity_type)
            if handler:
                handler(activity, activity_full_url)
            else:
                print(f"(process_step) •-> {activity_type}:
{activity['id']:>6} - {activity['title']} (kept as-is, no handler)")
```

Đệ quy: lồng `items`

```
        if 'items' in item:
             sub_content = []
             for sub in item['items']:
                 parsed = self._parse_lesson_item(sub)
                 if parsed:
                     sub_content.append(parsed)
             return "\n\n".join(sub_content)
```

Lặp có ngắt `break`

```
                page += 1
                if page > self.MAX_PAGES:
                    print(f"\nReached safety limit of {self.MAX_PAGES}
pages.")
                    break
```

- Tham số mặc định và `**kwargs` xuyên suốt:
  - `generate_markdown(toc_only=False, no_transcript=False, **kwargs)`.
- `lambda` làm khoá sắp xếp:
  - `sorted(collection.items(), key=lambda item: item[1])`.
- Các vòng `for` lồng nhau `module`, `step`, `activity` theo cấu trúc dữ liệu (trình bày ở chương 01).

3.9 XỬ LÝ NGOẠI LỆ

`services/store.py`: ghi nguyên tử

```
    path = Path(path)
    path.parent.mkdir(parents=True, exist_ok=True)
    fd, tmp = tempfile.mkstemp(dir=path.parent, prefix=".tmp-")
    try:
        with os.fdopen(fd, "w", encoding="utf-8", newline="\n") as
textfile:
            textfile.write(text)
            textfile.flush()
            os.fsync(textfile.fileno())
        os.replace(tmp, path)
    except BaseException:
        try:
            os.remove(tmp)
        except OSError:
            pass
        raise
```

`services/browser.py`: người dùng bỏ dở

```
    while "sign_in" in driver.current_url:
        suffix = f" for {what}" if what else ""
        print(f"\n\033[93m[!] Authentication required{suffix}.\033[0m")
        print("Please sign in to the browser window if you haven't.")
        try:
            input("Press Enter after you have signed in and the page is
loaded... ")
        except (KeyboardInterrupt, EOFError):
            print("\n\033[91mAborted authentication.\033[0m")
            return False
        driver.get(url)
```

1 Nguyên tắc liên tục

Một activity lỗi **không dừng**:

- `process_*` bắt, log, đi tiếp.
- Chỉ thiếu metadata hoặc outline mới dừng.

2 Các nguồn ngoại lệ

Thư viện (`NoSuchElementException`, `JSONDecodeError`), Python (`KeyboardInterrupt`, `EOFError`), và `ValueError` (cho type lạ).

3 `except BaseException`

- Dọn file tạm rồi `raise` lại: Ctrl+C không bao giờ để lại **nửa** file JSON.

3.10 DỮ LIỆU VÀ FILE, KHÔNG CÓ CSDL

```
data/                    # nguồn sự thật
├── index.json           # ledger, dựng lại được
├── paths/280.json
├── courses/892.json
├── courses/892-prompt.json
└── labs/2794.json
csbmdvault/
├── paths.md
├── paths/
├── courses/
├── labs/
└── materials/courses/892/*.pdf
```

```
$ skills-scraper reindex
   paths: 73   courses: 416   labs: 824
```

- Dưới 5.000 bản ghi: `grep` trả lời trong mili giây.
- Flat-file **git-friendly**; Editor đọc trực tiếp, không cần export.
- Stateless: chạy ở đâu cũng được (ví dụ đóng gói lên Cloud Run).
- v2.0.0 ghi song song TinyDB và JSON, đọc từ TinyDB; đã loại bỏ, JSON là nguồn sự thật duy nhất từ v2.0.1.

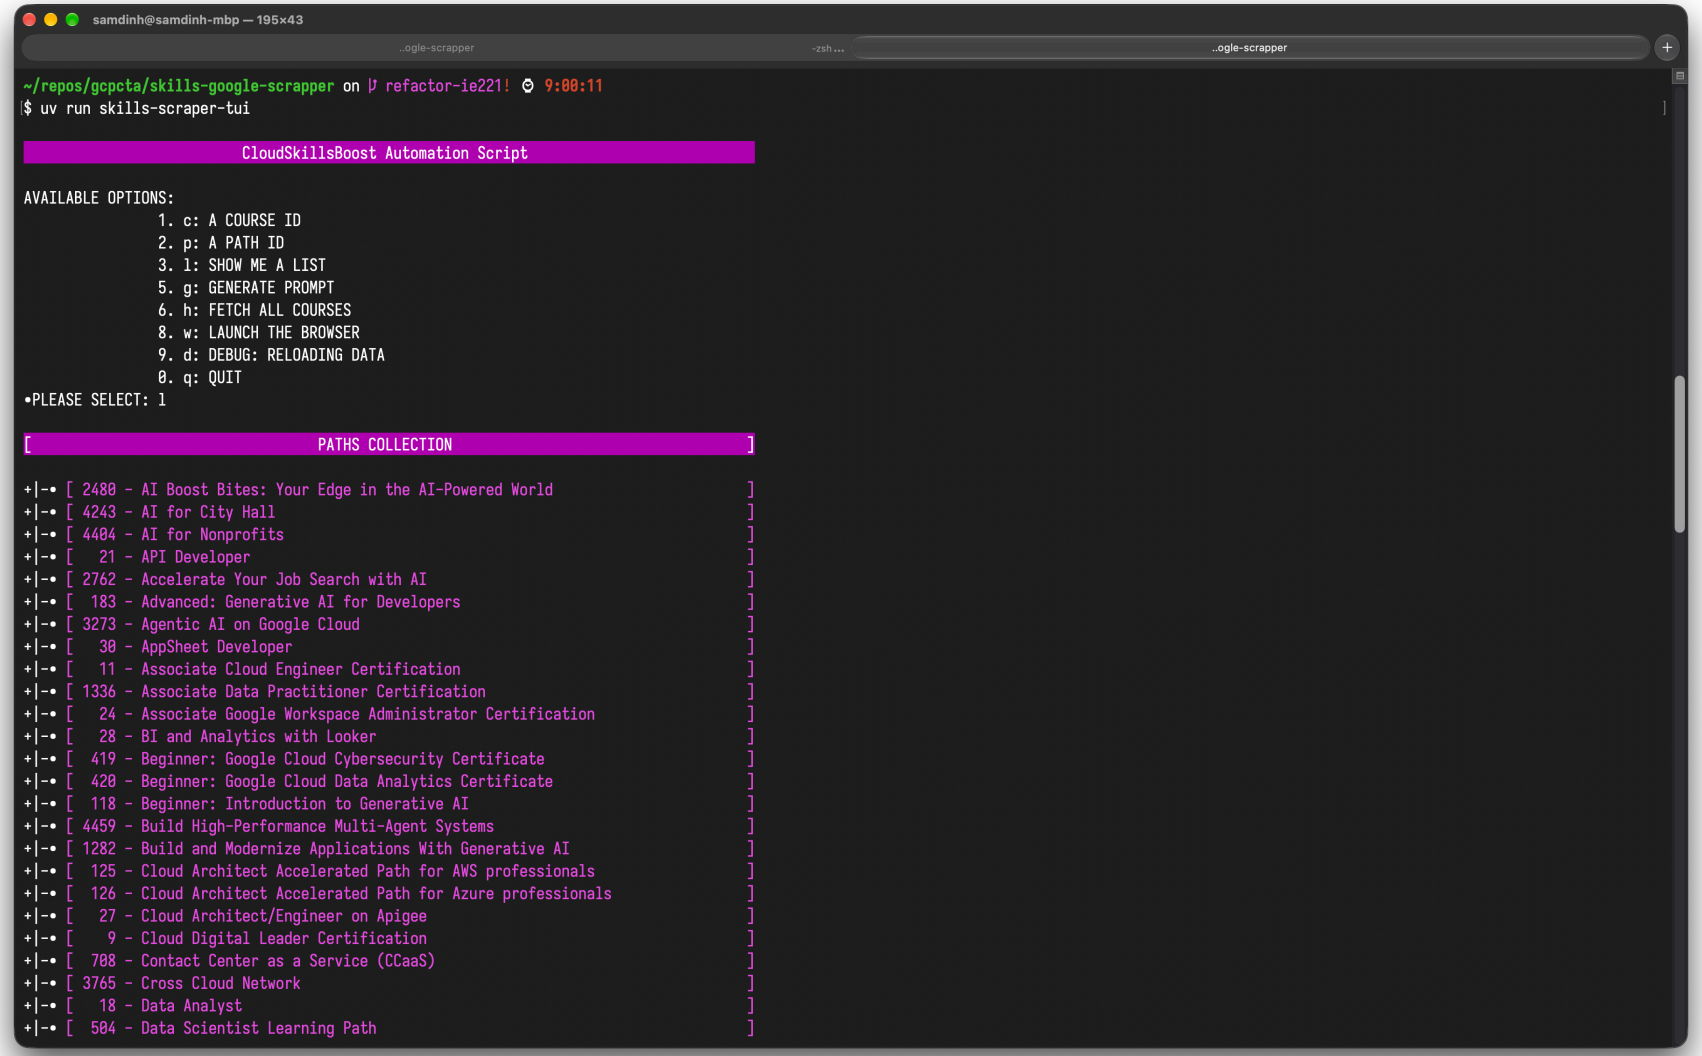
Database?

Kết nối CSDL là kỹ năng đã học. **Không dùng** ở đây là quyết định thiết kế có lý do, không phải bỏ sót: một package nhỏ, flat-file, stateless.

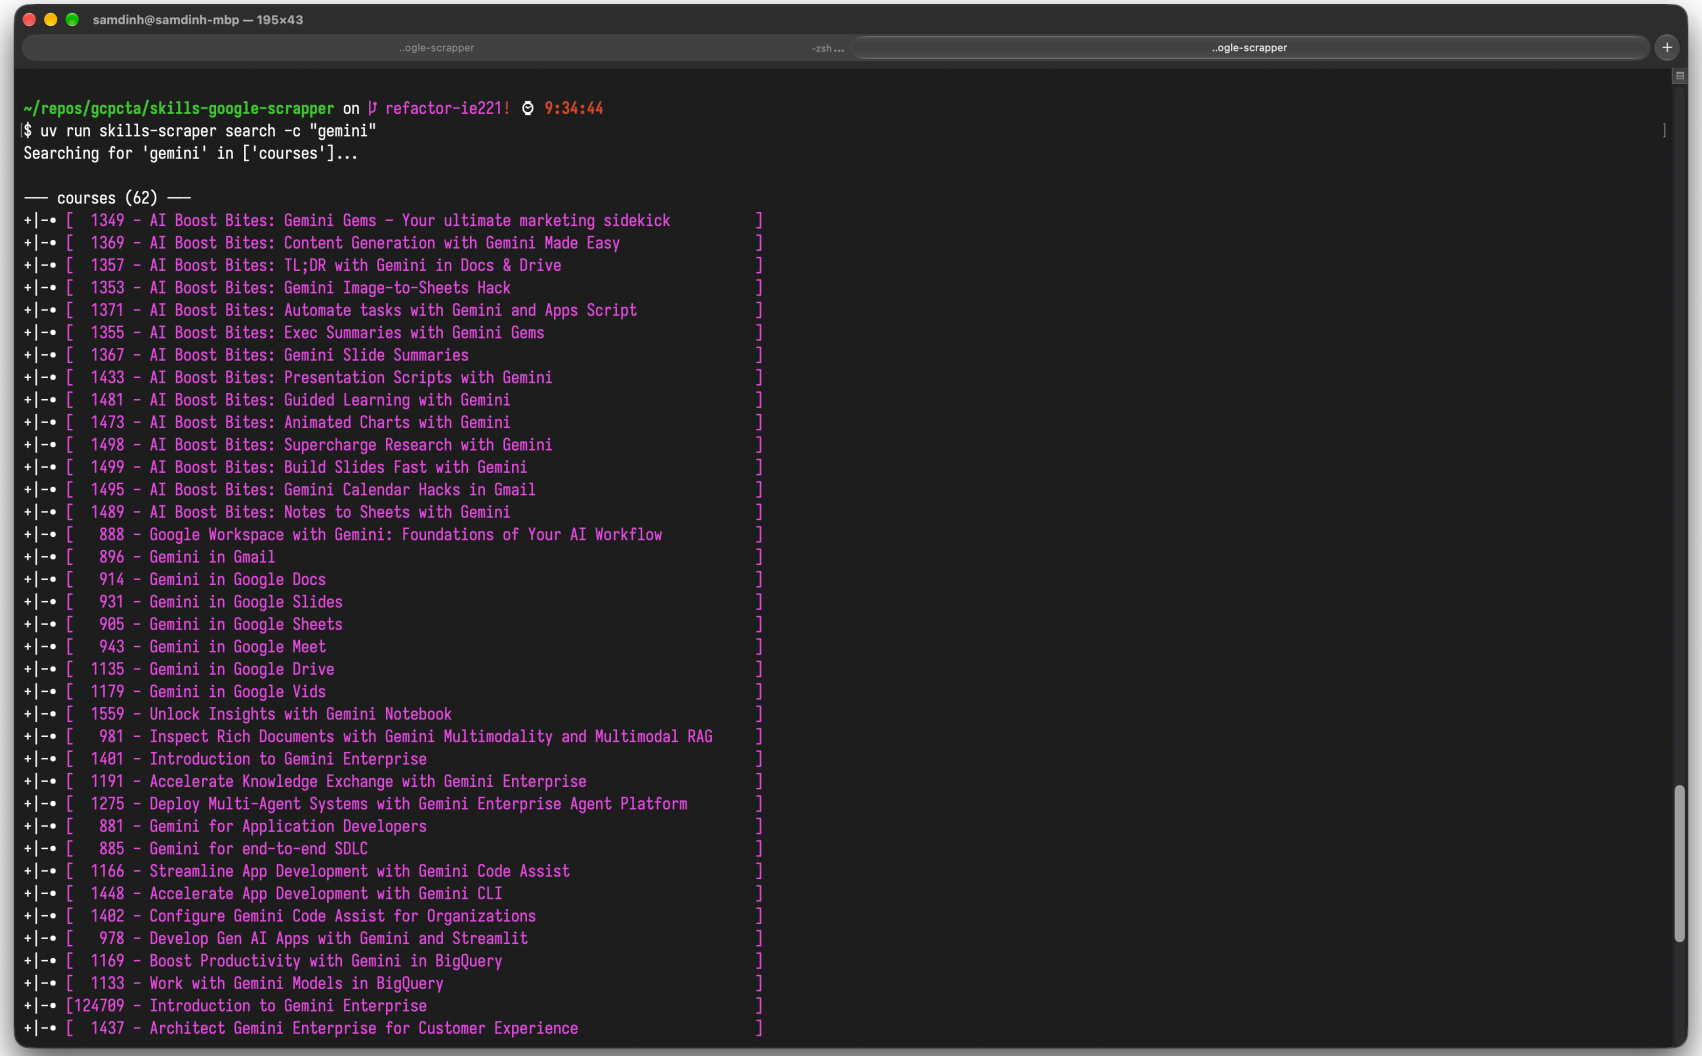
04

DEMO

4.1 TUI


samdinh@samdinh-mbp — 195×43
..ogle-scrapper
-zsh ...
..ogle-scrapper
~/repos/gcpcta/skills-google-scrapper on refactor-ie221! 9:00:11
$ uv run skills-scraper-tui
CloudSkillsBoost Automation Script
AVAILABLE OPTIONS:
1. c: A COURSE ID
2. p: A PATH ID
3. l: SHOW ME A LIST
5. g: GENERATE PROMPT
6. h: FETCH ALL COURSES
8. w: LAUNCH THE BROWSER
9. d: DEBUG: RELOADING DATA
0. q: QUIT
•PLEASE SELECT: l
PATHS COLLECTION
+|-• [2480 - AI Boost Bites: Your Edge in the AI-Powered World]
+|-• [4243 - AI for City Hall]
+|-• [4404 - AI for Nonprofits]
+|-• [21 - API Developer]
+|-• [2762 - Accelerate Your Job Search with AI]
+|-• [183 - Advanced: Generative AI for Developers]
+|-• [3273 - Agentic AI on Google Cloud]
+|-• [30 - AppSheet Developer]
+|-• [11 - Associate Cloud Engineer Certification]
+|-• [1336 - Associate Data Practitioner Certification]
+|-• [24 - Associate Google Workspace Administrator Certification]
+|-• [28 - BI and Analytics with Looker]
+|-• [419 - Beginner: Google Cloud Cybersecurity Certificate]
+|-• [420 - Beginner: Google Cloud Data Analytics Certificate]
+|-• [118 - Beginner: Introduction to Generative AI]
+|-• [4459 - Build High-Performance Multi-Agent Systems]
+|-• [1282 - Build and Modernize Applications With Generative AI]
+|-• [125 - Cloud Architect Accelerated Path for AWS professionals]
+|-• [126 - Cloud Architect Accelerated Path for Azure professionals]
+|-• [27 - Cloud Architect/Engineer on Apigee]
+|-• [9 - Cloud Digital Leader Certification]
+|-• [708 - Contact Center as a Service (CCaaS)]
+|-• [3765 - Cross Cloud Network]
+|-• [18 - Data Analyst]
+|-• [504 - Data Scientist Learning Path]

4.2 CLI


samdinh@samdinh-mbp — 195×43
..ogle-scrapper
-zsh ...
..ogle-scrapper
~/repos/gcpcta/skills-google-scrapper on refactor-ie221! 9:34:44
$ uv run skills-scraper search -c "gemini"
Searching for 'gemini' in ['courses']...
── courses (62) ──
+|-• [1349 - AI Boost Bites: Gemini Gems - Your ultimate marketing sidekick]
+|-• [1369 - AI Boost Bites: Content Generation with Gemini Made Easy]
+|-• [1357 - AI Boost Bites: TL;DR with Gemini in Docs & Drive]
+|-• [1353 - AI Boost Bites: Gemini Image-to-Sheets Hack]
+|-• [1371 - AI Boost Bites: Automate tasks with Gemini and Apps Script]
+|-• [1355 - AI Boost Bites: Exec Summaries with Gemini Gems]
+|-• [1367 - AI Boost Bites: Gemini Slide Summaries]
+|-• [1433 - AI Boost Bites: Presentation Scripts with Gemini]
+|-• [1481 - AI Boost Bites: Guided Learning with Gemini]
+|-• [1473 - AI Boost Bites: Animated Charts with Gemini]
+|-• [1498 - AI Boost Bites: Supercharge Research with Gemini]
+|-• [1499 - AI Boost Bites: Build Slides Fast with Gemini]
+|-• [1495 - AI Boost Bites: Gemini Calendar Hacks in Gmail]
+|-• [1489 - AI Boost Bites: Notes to Sheets with Gemini]
+|-• [888 - Google Workspace with Gemini: Foundations of Your AI Workflow]
+|-• [896 - Gemini in Gmail]
+|-• [914 - Gemini in Google Docs]
+|-• [931 - Gemini in Google Slides]
+|-• [905 - Gemini in Google Sheets]
+|-• [943 - Gemini in Google Meet]
+|-• [1135 - Gemini in Google Drive]
+|-• [1179 - Gemini in Google Vids]
+|-• [1559 - Unlock Insights with Gemini Notebook]
+|-• [981 - Inspect Rich Documents with Gemini Multimodality and Multimodal RAG]
+|-• [1401 - Introduction to Gemini Enterprise]
+|-• [1191 - Accelerate Knowledge Exchange with Gemini Enterprise]
+|-• [1275 - Deploy Multi-Agent Systems with Gemini Enterprise Agent Platform]
+|-• [881 - Gemini for Application Developers]
+|-• [885 - Gemini for end-to-end SDLC]
+|-• [1166 - Streamline App Development with Gemini Code Assist]
+|-• [1448 - Accelerate App Development with Gemini CLI]
+|-• [1402 - Configure Gemini Code Assist for Organizations]
+|-• [978 - Develop Gen AI Apps with Gemini and Streamlit]
+|-• [1169 - Boost Productivity with Gemini in BigQuery]
+|-• [1133 - Work with Gemini Models in BigQuery]
+|-• [124709 - Introduction to Gemini Enterprise]
+|-• [1437 - Architect Gemini Enterprise for Customer Experience]

XIN CẢM ƠN!

https://github.com/ggcta/skills-scrapper

Built with Typst and ♡